

- LLM генерируют текст с нейтральным «корпоративным» стилем – слабо учитывают особенности целевой аудитории.
- Prompt-tuning расходует контекстное окно и плохо работает с малыми моделями.
- Существующие методы решают перенос стиля одного автора, но не усвоение *коллективного* стиля сообщества.
- PEFT-методы потенциально позволяют адаптироваться к стилю при ограниченных данных и вычислительных ресурсах.

Цель работы

Целью данной работы является изучить применимость методов полного и параметро-эффективного дообучения языковых моделей к задаче стилевой адаптации текстовой генерации на русскоязычном корпусе комментариев из Telegram.

Поставленные задачи

Задачи:

- провести обзор существующих подходов к нейросетевой стилизации текста и методов параметро-эффективного дообучения языковых моделей;
- собрать, обработать и опубликовать датасет для задачи стилевой адаптации коллективного стиля на основе русскоязычных Telegram-каналов;
- формализовать постановку задачи стилевой адаптации в терминах каузального языкового моделирования;
- провести эксперименты по полному дообучению и методам LoRA и (IA)³ на LLM и исследовать влияние применения LoRA к различным группам слоёв трансформера;
- разработать способы оценивания качества стилевой адаптации;
- провести сравнительный анализ методов и проинтерпретировать результаты;

Обзор смежных работ

Классический TST

Shen et al., NeurIPS 2017; Jin et al., 2022

Подход: adversarial encoder-decoder, разделение «что» и «как».

Ограничение: только бинарные атрибуты, короткие предложения, английский язык.

Промптинг vs. дообучение

Mukherjee et al., INLG 2024

Подход: сравнение zero-shot / few-shot / LoRA на моделях 0.5B–30B.

Вывод: дообучение превосходит промптинг, особенно для грамматически сложных языков.

LoRA


Hu et al., ICLR 2022

Подход: обучение $< 1\%$ параметров через низкоранговые матрицы.

Результат: сопоставимо с полным дообучением при доле вычислений $\times 5000$ меньше.

Ни одна из работ не исследует адаптацию к **коллективному стилю сообщества** и не измеряет **катастрофическое забывание**.

Параметр	Значение
Каналов	7
Постов	4 637
Комментариев	10 300
Ср. длина коммент.	20,5 слова
Сплит (train/val/test)	80 / 10 / 10



Распределение длин комментариев
до и после предобработки

- Тематики: новости, ИИ, коммуникация
- Обезличен и **опубликован на HuggingFace**

Формальная постановка задачи дообучения

Задача – каузальное языковое моделирование. Каждый обучающий пример:

$$X = (x_1, \dots, x_k, y_1, \dots, y_m),$$

где $x_{1:k}$ – токены поста и служебные токены «Пост: <текст> Комментарий:», а $y_{1:m}$ – токены целевого комментария.

Функция потерь:


$$\mathcal{L}(\theta) = - \sum_{i=1}^N \sum_{j=1}^m \log p_{\theta} \left(y_j^{(i)} \mid x^{(i)}, y_{<j}^{(i)} \right).$$

Ключевая деталь

Потери считаются *только по токенам комментария*; токены поста маскируются и используются исключительно как контекст.

Метрики оценки качества

Функция потерь на валидации — **ненадёжный** критерий останова: SE по единственному референсу не отражает множество допустимых откликов. Поэтому качество оценивается набором метрик:



Оценивание стилевой неотличимости

Ни одна из перечисленных метрик не оценивает **стилистическую неотличимость** отклика от человеческого. Для этого использовался подход LLM-as-a-Judge, развивающий идею теста Тьюринга.

Гипотеза

Модель усвоила коллективный стиль сообщества, если её генерации неотличимы от реальных комментариев в контексте конкретного поста.

- Судье (GPT-5 nano) даётся пост, k реальных комментариев и один сгенерированный – нужно **указать сгенерированный**;
- метрика — точность судьи против порога случайного угадывания (29,6%);
- чем **ниже** точность, тем лучше усвоен стиль.

Методы дообучения

- **Полное дообучение (Full FT)** – обновление всех параметров модели.
- **LoRA (Low-Rank Adaptation)** – обновление весов через низкоранговую декомпозицию:

$$W + \Delta W = W + AB, \quad A \in \mathbb{R}^{d \times r}, \quad B \in \mathbb{R}^{r \times l}, \quad r \ll \min(d, l).$$

- **(IA)³** – масштабирование внутренних активаций модели. Обучаются лишь три встроенных вектора внутренней размерности d .

Метод	Модель	Optimizer	lr	batch	эпохи	post/total	r/α	Обучаемые модули
Full FT	ruGPT3-small	AdamW	$5 \cdot 10^{-5}$	8	3	256/384	–	все веса
Full FT	ruGPT3-medium	AdamW	$5 \cdot 10^{-5}$	8	3	256/384	–	все веса
Full FT	Qwen2.5-0.5B	AdamW	$5 \cdot 10^{-5}$	8	3	384/512	–	все веса
LoRA $r=8$	Qwen2.5-0.5B	AdamW	$2 \cdot 10^{-4}$	8	8	384/512	8/16	q_proj, v_proj
LoRA $r=16$	Qwen2.5-0.5B	AdamW	$2 \cdot 10^{-4}$	8	8	384/512	16/32	q_proj, v_proj
LoRA $r=32$	Qwen2.5-0.5B	AdamW	$2 \cdot 10^{-4}$	8	8	384/512	32/64	q_proj, v_proj
LoRA FFN	Qwen2.5-0.5B	AdamW	$2 \cdot 10^{-4}$	8	8	384/512	8/16	gate_proj, up_proj, down_proj
LoRA Attn	Qwen2.5-0.5B	AdamW	$2 \cdot 10^{-4}$	8	8	384/512	8/16	q_proj, k_proj, v_proj, o_proj


Результаты: стандартные метрики

- **Перплексия на Wikipedia** — индикатор забывания: у моделей с высокой `ppl_wiki` судья чаще выявляет артефакты генерации.
- **Перплексия на комментариях** — отражает адаптацию к домену, но не качество стиля.
- **Лексическое разнообразие (`comb_d2`)** — **необходимая, но недостаточная** метрика: ловит заикливания, но не стилевое соответствие.
- **BERTScore** — малоинформативен на этом корпусе: значения почти не различаются между конфигурациями.

Метод	comb d2	ppl comm	ppl wiki	BS post	BS ref
ruGPT3 base	0,548	191,7	22,6	0,611	0,591
Qwen base	0,675	40,9	11,3	0,632	0,600
ruGPT3 FT (эп. 1)	0,700	64,9	38,8	0,645	0,642
Qwen FT (эп. 2)	0,659	38,2	67,9	0,646	0,629
LoRA $r=16$ (эп. 2)	0,745	24,9	28,8	0,621	0,626
LoRA $r=32$ (эп. 4)	0.763	26.2	41.7	0.633	0.634

Результаты: LLM-as-a-Judge

- **ruGPT3-small** — лучшая неотличимость: точность судьи **26–31%**, на уровне случайного угадывания (29,6%) или ниже.
- Такой результат вопреки катастрофическому забыванию и высокой перплексии.
- ⇒ валидационный лосс **не** отражает качество стилизации.
- Базовые модели — худшие (Qwen base 70%): дообучение сработало.



Заключение

В ходе работы были выполнены следующие задачи:

- Проведен обзор существующих подходов к применению нейросетей в задаче стилизации текста и методов дообучения языковых моделей;
- Собран и опубликован датасет для задачи адаптации коллективного стиля;
- Формализована постановка задачи стилевой адаптации;
- Проведены эксперименты по дообучению обозначенными методами и проанализировано их влияние на различные блоки;
- Разработаны способ оценивания качества стилевой адаптации;
- Проведен сравнительный анализ методов и проинтерпретированы результаты.

В работе проведено исследование о применимости методов полного и параметро-эффективного дообучения языковых моделей к задаче адаптации коллективного стиля на

Примеры генераций

Пост (id 104)

Мощный пожар в ангаре на Маршала Новикова — у цеха спецавтоматики небо заволокло густым чёрным дымом. Информация о пострадавших не поступала. Службы выехали на место эмодзи

Реальные комментарии:

«Ну йопрст. Понедельник же. Ну»

«ну что, все уже сняли и скинули видео?»

Не распознанные примеры

LoRA $r=32$ ep. 2: «а как это было?»

ruGPT3-small ep. 3: «Такое ощущение, что кто-то просто хочет отравиться и напугать людей»

Артефакты (зацикливания, бессвязность)

LoRA $r=8$: «а как это все обусловлено? ветер, дождь, неизвестные подводные камни, навесы, бомжи, упавшиеся на землю, снег...»

LoRA FFN ep. 2: «Не могло бы быть, если бы эти специалисты были специалистами, не могли бы быть?»

Базовая модель *ruGPT3 base*: «Это был не тот пожар <...> Бред какой-то. Это просто не могло быть правдой. Вполне возможно, что этот пожар произошёл из-за того, что...»

Ссылки на проект



GitHub



Hugging Face

Список литературы

- 1 Shen et al. Style transfer from non-parallel text by cross-alignment // NeurIPS, 2017.
- 2 Fu et al. Style transfer in text: exploration and evaluation // AAAI, 2018.
- 3 Radford et al. Language models are unsupervised multitask learners // OpenAI Blog, 2019.
- 4 Jiang et al. SMART: robust and efficient fine-tuning for pre-trained NLM // arXiv:1911.03437, 2019.
- 5 Luo et al. Catastrophic forgetting in LLMs during continual fine-tuning // arXiv:2308.08747, 2023.
- 6 Lialin et al. Scaling down to scale up: a guide to PEFT // arXiv:2303.15647, 2023.
- 7 Aghajanyan et al. Intrinsic dimensionality explains the effectiveness of LM fine-tuning // arXiv:2012.13255, 2020.
- 8 Hu et al. LoRA: low-rank adaptation of large language models // ICLR, 2022.
- 9 Liu et al. Few-shot parameter-efficient fine-tuning is better and cheaper than in-context learning // arXiv:2205.05638, 2022.
- 10 Keles et al. On the computational complexity of self-attention // arXiv:2209.04881, 2022.
- 11 Zhang et al. BERTScore: evaluating text generation with BERT // arXiv:1904.09675, 2020.
- 12 Zmitrovich et al. A family of pretrained transformer LMs for Russian // LREC-COLING, 2024.
- 13 Yang et al. Qwen2.5 technical report // arXiv:2412.15115, 2024.
- 14 Wikimedia Foundation. Wikimedia downloads. dumps.wikimedia.org.

Temporary page!

$\text{\LaTeX}$ was unable to guess the total number of pages correctly. As there was some unprocessed data that should have been added to the final page this extra page has been added to receive it. If you rerun the document (without altering it) this surplus page will go away, because $\text{\LaTeX}$ now knows how many pages to expect for this document.